

IS-RAG: Geração Aumentada por Recuperação baseada em Esquemas Imagéticos para Busca Cognitiva em Discurso Político

Autor Um¹ Autor Dois¹ Autor Três²

¹ Instituição Um ² Instituição Dois

{autor1, autor2}@inst1.edu autor3@inst2.edu

Resumo

Objetivo. Sistemas de recuperação densa falham quando o usuário e o documento expressam a mesma estrutura conceitual por vocabulários distintos — fenômeno que denominamos *lacuna léxico-cognitiva*. Este artigo apresenta o **IS-RAG**, um estudo piloto que investiga se a indexação explícita de *esquemas imagéticos* (Lakoff and Johnson, 1980; Talmy, 1988) — padrões pré-linguísticos como FORCE, CONTAINER e PATH — pode superar essa lacuna em um corpus de discurso político em português.

Método. Durante a indexação, um *Analizador Cognitivo* baseado em LLM anota cada trecho com os esquemas imagéticos presentes, gerando metadados estruturados armazenados juntamente com dois embeddings vetoriais independentes: um textual e um cognitivo (768d cada). Em tempo de consulta, os esquemas detectados na consulta disparam um *boost proporcional* sobre os trechos que compartilham a mesma estrutura cognitiva, possibilitando recuperação orientada por metáfora abstrata além da sobreposição lexical.

Avaliação. Construímos um ground truth estilo TREC sobre 121 discursos parlamentares brasileiros (171 trechos), com 9 consultas válidas (3 FORCE + 2 CONTAINER + 3 PATH + 1 cross-schema) anotadas por LLM em escala 0–3. A métrica principal é NDCG@5; a linha de base é recuperação densa sem boosting cognitivo.

Achados. O IS-RAG atinge NDCG@5 médio de 0,7073 contra 0,6947 da linha de base ($\Delta = +0,013$). Os ganhos concentram-se nas consultas FORCE ($\Delta_{\text{FORCE}} = +0,210$); CONTAINER e PATH apresentam resultados neutros ou negativos ($\Delta_{\text{família}} = -0,017$). Dois achados metodológicos emergem: (1) consultas devem ser formuladas como *afirmações metafóricas assertivas* para ativar o componente cognitivo; (2) frequência de esquema no corpus não prediz anotabilidade — esquemas convencionizados resistem ao julgamento de relevância.

Palavras-chave: geração aumentada por recuperação · esquemas imagéticos · linguística cognitiva · recuperação de informação · processamento de linguagem natural · detecção de metáfora · recuperação densa · discurso político · busca semântica · cognição corporificada

1. Introdução

A Geração Aumentada por Recuperação (Lewis et al., 2020) tipicamente fundamenta a recuperação de documentos em similaridade lexical superficial ou semântica densa. Isso funciona bem quando o vocabulário da consulta se sobrepõe ao vocabulário do documento, mas falha diante de uma *lacuna léxico-cognitiva*: o usuário e o documento expressam a mesma estrutura conceitual usando palavras diferentes, frequentemente porque ambos se apoiam em metáforas corporais subjacentes que mapeiam a experiência espacial física sobre domínios abstratos (Johnson, 1987; Lakoff and Johnson, 1980).

Considere uma consulta sobre *pressão econômica sobre as famílias* e um discurso parlamentar sobre *instituições que se bloqueiam mutuamente em uma disputa constitucional*. Ambos invocam o esquema imagético FORCE/COMPULSION — um agente externo exercendo força sobre um paciente —, porém seus vocabulários compartilham pouca sobreposição, tornando a recuperação densa padrão incapaz de superar essa lacuna.

Esquemas imagéticos (Feldman, 2006; Johnson, 1987) são padrões pré-linguísticos e corporificados (CONTAINER, PATH, FORCE) que recorrem como metáforas estruturais em todos os domínios do raciocínio abstrato. Nossa hipótese é que indexar esses esquemas explicitamente e combiná-los em tempo de consulta viabiliza uma forma de recuperação estrutural profunda que complementa a busca semântica densa.

Contribuições.

- Apresentamos o IS-RAG, uma técnica que indexa metadados de esquemas imagéticos juntamente com embeddings vetoriais duais (texto e cognitivo) e aplica boosting cognitivo proporcional em tempo de recuperação (§3).
- Construímos um ground truth estilo TREC sobre um corpus real de discursos parlamentares brasileiros (171 trechos, 9 consultas válidas, LLM como anotador) e reportamos NDCG@5 (§4).
- Identificamos restrições metodológicas para avaliação de recuperação ciente de esquemas: formulação assertiva de consultas, frequência vs. anotabilidade de esquemas e risco de circularidade com LLM (§6).

2. Trabalhos Relacionados

Geração Aumentada por Recuperação. Lewis et al. (2020) introduziram o RAG para fundamentar a geração em passagens recuperadas. A recuperação densa com representações bi-encoder (Karpukhin et al., 2020) tornou-se o backbone padrão. Extensões exploram busca híbrida esparsa-densa, re-ranking e augmentação por conhecimento estruturado, mas nenhuma incorpora metáfora espacial pré-linguística como sinal de recuperação.

Metáfora em PLN. A detecção automática de metáfora foi estudada como classificação ou extração de spans (Shutova, 2010; Tsvetkov et al., 2014). Wachowiak and Gromann (2022, 2023) exploram LLMs para identificação de metáforas. Esses trabalhos focam na *detecção* de metáforas; o IS-RAG é o primeiro, ao nosso conhecimento, a utilizar a estrutura de esquema imagético detectado como *sinal de pontuação de recuperação*.

Linguística Cognitiva e RI. Esquemas imagéticos como universais cognitivos foram formalizados por Lakoff and Johnson (1980), Johnson (1987) e Talmy (1988). Feldman (2006) discute sua base neural. Nenhum trabalho anterior em Recuperação de Informação indexa documentos por esquema imagético e utiliza correspondência de esquemas para boosting de recuperação.

PLN em Português e corpora parlamentares. Modelos de linguagem pré-treinados para o português brasileiro (Souza et al., 2020) demonstraram que o pré-treinamento específico ao idioma melhora substancialmente o desempenho em tarefas downstream em relação a modelos multilíngues genéricos. O discurso parlamentar em português foi estudado por meio do Corpus Ulysses (Albuquerque et al., 2022), coleção de documentos legislativos da Câmara dos Deputados brasileira utilizada para classificação de textos, reconhecimento de entidades e análise semântica. Nosso corpus de avaliação é extraído da mesma fonte institucional via mesma API aberta e estende os recursos existentes com anotações de esquemas imagéticos e julgamentos de relevância graduada para avaliação de recuperação. Análises de enquadramento e sentimento em texto político brasileiro (Vargas et al., 2021) fornecem precedente adicional para abordagens computacionais da estrutura ideológica na linguagem parlamentar em português.

3. Método

A Figura 1 ilustra o pipeline IS-RAG. O pseudocódigo formal encontra-se no Apêndice B.




Figura 1: Visão geral do IS-RAG: etapas de indexação e recuperação.

3.1. Corpus e Segmentação

O corpus compreende 121 discursos parlamentares brasileiros em **português**, coletados da API aberta da Câmara dos Deputados (dados.camara.leg.br/api/v2), abrangendo janeiro a dezembro de 2025. Os discursos são estratificados por espectro ideológico (esquerda, centro, direita) em 13 partidos. Cada discurso é segmentado em trechos de aproximadamente 150 palavras por meio de divisão em fronteiras de sentenças, gerando 171 trechos (média de 2,7 por discurso).

3.2. Embeddings Duais

Cada trecho produz dois vetores independentes de 768 dimensões:

1. **Embedding textual:** representação densa do texto bruto do trecho via *paraphrase-multilingual-mpnet-base-v2* (Reimers and Gurevych, 2019), executado localmente em CPU.
2. **Embedding cognitivo:** representação densa dos metadados cognitivos serializados no formato "SCHEMA: âncora → domínio | ...", capturando a estrutura esquemático-imagética independentemente do vocabulário literal.

Ambos os vetores são armazenados no PostgreSQL 16 com a extensão *pgvector* e indexados via HNSW para busca aproximada do vizinho mais próximo.

Escolhemos deliberadamente o *paraphrase-multilingual-mpnet-base-v2* em vez de APIs comerciais de embedding mais recentes por duas razões. Primeiro, *reprodutibilidade*: todos os embeddings são gerados localmente, sem acesso a API, limites de taxa ou custos de uso, possibilitando replicação integral do experimento. Segundo, *adequação*: o modelo oferece cobertura validada do português em um espaço de 768 dimensões suficiente para a escala de prova de conceito deste trabalho (171 trechos), e seu treinamento multilíngue inclui o português brasileiro (Souza et al., 2020). Não afirmamos que a substituição por modelos de embedding maiores ou mais recentes não melhoraria os resultados; isso é um item explícito da agenda futura (§7), mas é ortogonal à variável sob investigação — o próprio sinal de boosting cognitivo.

3.3. Analisador Cognitivo

O Analisador Cognitivo envia cada trecho para o `claude-haiku-4-5` (Anthropic, 2024) usando um prompt compartilhado (Apêndice A) e extrai JSON estruturado validado por um schema Pydantic. A taxonomia segue Lakoff and Johnson (1980) e Talmy (1988):

Esquema	Subtipos
CONTAINER	Inside, Outside, Boundary, Intrusion
PATH	Source, Trajectory, Goal, Diversion
FORCE	Blockage, Compulsion, Resistance, Counter_Force

Uma *regra de literalidade* instrui o modelo a retornar listas vazias para textos não-metafóricos, prevenindo esquemas alucinados. Os trechos são processados concorrentemente (5 workers) para reduzir o tempo de ingestão. O corpus apresenta 92 ocorrências de PATH, 88 de CONTAINER e 83 de FORCE nos 171 trechos.

3.4. Busca Híbrida e Boosting Cognitivo

O IS-RAG suporta três modos de recuperação: *texto* (apenas embedding textual), *cognitivo* (apenas embedding cognitivo) e *híbrido* (média de ambas as similaridades). Após computar a similaridade vetorial base s , aplica-se um *boost cognitivo proporcional*:

$$\hat{s} = s \cdot (1 + 0,4\sigma + 0,3\delta) \quad (1)$$

onde σ é a fração dos detalhes cognitivos de um trecho cujo `schema_name` corresponde a um esquema detectado na consulta, e δ é a fração análoga para `target_domain`. Os pesos ($\alpha=0,4$, $\beta=0,3$) foram definidos por design; a estrutura esquemática é o sinal primário e o domínio é o reforço secundário. A linha de base desativa o Analisador Cognitivo e aplica recuperação puramente por embedding textual sem boosting.

4. Configuração da Avaliação

Construção do Ground Truth. Construímos um ground truth por pooling estilo TREC (Voorhees and Harman, 2005). Para cada consulta, o IS-RAG (híbrido) e a linha de base recuperam independentemente os 10 trechos mais relevantes; a união ($\approx 14-18$ trechos únicos por consulta) é anotada quanto à relevância (0-3) por um LLM (`claude-haiku-4-5`). Pontuações ≥ 2 exigem que o anotador cite uma palavra-âncora e o subtipo de esquema como evidência rastreável. Consultas com IDCG= 0 (nenhum trecho com pontuação ≥ 2) são excluídas (Buckley and Voorhees, 2004); esse critério provocou a exclusão de uma consulta (cf. §6).

Projeto das Consultas. Nove consultas válidas foram projetadas com três propriedades: (1) cobertura taxonômica (3 FORCE + 2 CONTAINER + 3 PATH + 1 cross-schema); (2) lacuna lexical deliberada (as consultas usam linguagem metafórica assertiva, evitando o vocabulário literal esperado nos documentos); (3) cenários entre domínios (as consultas visam esquemas que aparecem em domínios distintos do domínio da própria consulta).

Métrica. Reportamos NDCG@5 (Järvelin and Kekäläinen, 2002). O MRR foi rejeitado: com múltiplos documentos relevantes em diferentes graus de relevância, o MRR satura em 1,0 independentemente da qualidade do ranqueamento (Buckley and Voorhees, 2004).

5. Resultados

5.1. Resultados por Consulta

A Tabela 1 reporta o NDCG@5 do IS-RAG e da linha de base nas 9 consultas válidas (modo híbrido). A Figura 2 visualiza o Δ por consulta.

Q	Esquema / Domínio	IS-RAG	Base	Δ
Q2	FORCE/Compulsion / Economia	0,8375	0,5308	+0,307
Q3	FORCE/Counter_F / Justiça	0,9093	0,6590	+0,250
Q4	FORCE/Resistance / Política	0,6548	0,5818	+0,073
Q5	CONT./Intrusion / Justiça	0,6403	0,9105	-0,270
Q6	CONT./Outside / Dir. Hum.	0,7833	0,7226	+0,061
Q7	PATH/Trajectory / Economia	0,6488	0,6488	$\pm 0,000$
Q8	PATH/Source / Política	0,5745	0,6972	-0,123
Q9	PATH/Diversion / Política	0,7777	0,8527	-0,075
Q10	FORCE+PATH / Rel. Int.	0,5397	0,6488	-0,109
Média (9 consultas)		0,7073	0,6947	+0,013

Tabela 1: NDCG@5 (IS-RAG vs. linha de base, modo híbrido). Consultas agrupadas por família de esquema.




Figura 2: Δ NDCG@5 por consulta (IS-RAG – linha de base).

5.2. Análise por Esquema

A Tabela 2 agrega os resultados por família de esquema. A média não ponderada ($\Delta = +0,013$) mascara forte heterogeneidade: FORCE concentra todos os ganhos, enquanto CONTAINER e PATH são neutros ou negativos. A ponderação igualitária entre as quatro famílias de esquema produz $\Delta_{\text{família}} = -0,017$.

Família	<i>n</i>	Δ médio	Δ individuais
FORCE	3	+0,210	+0,307, +0,250, +0,073
CONTAINER	2	-0,105	-0,270, +0,061
PATH	3	-0,066	0,000, -0,123, -0,075
Cross	1	-0,109	-0,109
Média ponderada por família		-0,017	

Tabela 2: Δ NDCG@5 por família de esquema (modo híbrido).

6. Discussão

Force é o maior beneficiário do boosting cognitivo. Todas as três consultas FORCE apresentam Δ positivo, com COMPULSION (+0,307) e COUNTER_FORCE (+0,250) como os resultados mais expressivos. Esquemas FORCE tendem a empregar vocabulário metafórico saliente e não convencionalizado no discurso parlamentar (*pressiona, bloqueia, choca*), tornando a detecção e o boosting eficazes. Esse padrão é específico do corpus e não deve ser generalizado sem validação adicional.

Path e Container não se beneficiam. As metáforas PATH aparecem tão convencionalizadas no registro parlamentar que não discriminam trechos relevantes dos não relevantes. CONTAINER/INTRUSION (Q5) foi projetada para o modo *cognitivo*; a execução forçada em modo híbrido explica parte da degradação ($\Delta = -0,270$).

A formulação assertiva das consultas é obrigatória. O Analisador Cognitivo aplica uma regra de literalidade: consultas interrogativas ou analíticas (“*Quais deputados argumentam que...*”) são corretamente classificadas como não-metafóricas, retornando listas de esquemas vazias e zerando o boost. As consultas devem ser formuladas como *afirmações metafóricas assertivas* para ativar o componente cognitivo. Esta é uma restrição operacional vinculante para qualquer implantação do IS-RAG.

Frequência de esquema $\neq$ anotabilidade. Q1 foi projetada como CONTAINER/INSIDE, o subtipo mais frequente no corpus (80 ocorrências). Apesar da alta frequência, o anotador consistentemente atribuiu pontuação 1 aos trechos INSIDE (domínio presente, esquema não-saliente) em vez de ≥ 2 (instanciação metafórica clara). A contenção espacial está tão convencionalizada no discurso parlamentar que não constitui um sinal discriminativo de relevância. Q1 foi excluída (IDCG=0), resultando na distribuição final 3-2-3-1 de consultas.

Limitações. (1) O corpus é pequeno e homogêneo (171 trechos, único registro, somente português); os resultados carecem de testes de significância estatística. (2) *Circularidade com LLM*: o mesmo modelo anota, analisa e aplica boosting — criando risco de que o anotador favoreça trechos que o analisador indexou com os mesmos esquemas da consulta. Uma auditoria humana cega sobre 20% da amostra do pool anotado será realizada em trabalhos futuros para calcular o índice de concordância Kappa de Fleiss entre juízes humanos independentes e o anotador LLM. (3) Confundimento por domínio: as consultas FORCE se concentram em Economia e Justiça; se o esquema co-ocorre com esses domínios no corpus, os ganhos podem refletir afinidade de domínio em vez de estrutura puramente cognitiva. (4) Os pesos de boosting ($\alpha=0,4$, $\beta=0,3$) são escolhas de projeto, não otimizadas.

7. Conclusão

Este artigo apresenta o IS-RAG como um estudo piloto pioneiro que abre uma nova linha de pesquisa na interseção entre linguística cognitiva e recuperação de informação. A contribuição central não é uma afirmação de superioridade universal, mas a demonstração de que metadados de esquemas imagéticos podem ser codificados, detectados e aproveitados dentro de um pipeline de recuperação densa padrão — produzindo ganhos mensuráveis de NDCG@5 para consultas FORCE em modo híbrido ($\Delta_{\text{FORCE}} = +0,210$) em um corpus parlamentar brasileiro real.

Os resultados assimétricos entre as famílias de esquema são em si um achado: revelam que a frequência de um esquema no corpus não prediz sua anotabilidade, e que a relação entre estrutura cognitiva e relevância de recuperação é não-trivial e merece investigação sistemática. O IS-RAG estabelece a prova de conceito e o arcabouço metodológico — embeddings duais, boosting cognitivo, avaliação estratificada por esquema estilo TREC — sobre os quais trabalhos futuros em *RI cognitiva* poderão se construir.

Os próximos passos imediatos incluem um design de avaliação cruzada esquema×domínio, investigação de esquemas convencionalizados na anotação de relevância graduada, validação em outros registros e idiomas, e a auditoria humana com Kappa de Fleiss descrita acima. Convidamos as comunidades de RI e linguística cognitiva a estender, questionar e refinar esta técnica em corpora mais ricos e arquiteturas de recuperação mais diversas.

Disponibilidade de Código e Dados. Código-fonte, corpus e ground truth anotado estão publicamente disponíveis em <https://github.com/yanjustino/is-rag>.

Referências

- Hidemberg O. Albuquerque, Lucas O. Costa, Gabriel D. Silveira, João P. Tarrega, Albertina Rossi, André C. P. L. F. de Carvalho, and Gladston Silva. UlyssesNER-Br: A corpus for named entity recognition in Brazilian legislative texts. In *Proceedings of the 15th International Conference on Computational Processing of Portuguese (PROPOR)*, pages 3–14. Springer, 2022.
- Anthropic. Claude haiku: Fast, compact model for near-instant responsiveness. Technical report, Anthropic, 2024. <https://www.anthropic.com/claude>.
- Chris Buckley and Ellen M. Voorhees. Retrieval evaluation with incomplete information. In *Proceedings of SIGIR*, pages 25–32, 2004.
- Jerome Feldman. *From Molecule to Metaphor: A Neural Theory of Language*. MIT Press, 2006.
- Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002.
- Mark Johnson. *The Body in the Mind: The Bodily Basis of Meaning, Imagination, and Reason*. University of Chicago Press, 1987.
- Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell wagons Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of EMNLP*, pages 6769–6781, 2020.
- George Lakoff and Mark Johnson. *Metaphors We Live By*. University of Chicago Press, 1980.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.
- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of EMNLP-IJCNLP*, pages 3982–3992, 2019.
- Ekaterina Shutova. Models of metaphor in NLP. In *Proceedings of ACL*, pages 688–697, 2010.
- Fábio Souza, Rodrigo Nogueira, and Roberto Lotufo. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Proceedings of the 9th Brazilian Conference on Intelligent Systems (BRACIS)*, pages 401–415. Springer, 2020.
- Leonard Talmy. Force dynamics in language and cognition. *Cognitive Science*, 12(1):49–100, 1988.
- Yulia Tsvetkov, Leonid Boytsov, Anatole Gershman, Eric Nyberg, and Chris Dyer. Metaphor detection with cross-lingual model transfer. In *Proceedings of ACL*, pages 248–258, 2014.

- Felipe Vargas, Marco A. Casanova, Julio C. S. Reis, and Fabrício Benevenuto. Contextualized word embeddings for political discourse analysis in Brazilian Portuguese. In *Proceedings of the Brazilian Symposium on Databases (SBB D)*, pages 13–24. SBC, 2021.
- Ellen M. Voorhees and Donna K. Harman. *TREC: Experiment and Evaluation in Information Retrieval*. MIT Press, 2005.
- Lennart Wachowiak and Dagmar Gromann. Systematic analysis of image schemas in natural language through explainable multilingual neural language processing. In *Proceedings of the 29th International Conference on Computational Linguistics (COLING)*, pages 5571–5581, 2022. URL <https://aclanthology.org/2022.coling-1.493/>.
- Lennart Wachowiak and Dagmar Gromann. Does GPT-3 grasp metaphors? Exploring the metaphor understanding of large language models. In *Proceedings of ACL*, pages 9857–9873, 2023.

A. Prompt de Análise Cognitiva

O prompt a seguir é compartilhado entre o pipeline de indexação (`ingestion.py`) e a etapa de análise de consultas (`search.py`). Está escrito em **português** para corresponder ao idioma do corpus e preservar a precisão terminológica nos exemplos *few-shot*. O marcador `{text}` é substituído em tempo de execução pelo texto do trecho ou da consulta.

Você é um linguista cognitivo especialista na Teoria da Metáfora Conceptual de Lakoff e nas Dinâmicas de Força de Talmy. Sua missão é analisar um texto em português extraído de discursos parlamentares, identificar os Esquemas Imagéticos dominantes e mapear como eles estruturam conceitos abstratos.

Analise o texto seguindo rigorosamente esta taxonomia:

1. MACROESQUEMAS E SUBTIPOS VÁLIDOS:

– CONTAINER:

- * INSIDE (Estar contido, protegido, preso, engessado)
- * OUTSIDE (Estar fora, excluído, marginalizado)
- * BOUNDARY (Fronteiras, limites, barreiras de contenção)
- * INTRUSION (Invasão, penetração forçada no recipiente)

– PATH:

- * SOURCE (Ponto de partida, origem, base histórica)
- * TRAJECTORY (Movimento, progresso, passos, rumo)
- * GOAL (Destino, objetivo final, chegada)
- * DIVERSION (Desvio de rota, perda de foco, sabotagem)

– FORCE:

- * BLOCKAGE (Bloqueio completo, barreira física/legal)
- * COMPULSION (Força externa que empurra, obriga, coage)
- * RESISTANCE (Resistência interna, oposição ativa)
- * COUNTER_FORCE (Duas forças colidindo, embate direto)

2. REGRAS PARA `target_domain_pt` (lista fechada):

"Economia" | "Política" | "Infraestrutura e Transportes"
| "Segurança Pública" | "Justiça" | "Direitos Humanos e
Cultura" | "Educação" | "Saúde" | "Meio Ambiente"
| "Relações Internacionais" | "Outros"

3. REGRA DE LITERALIDADE:

Se o texto for puramente literal, descritivo, técnico ou administrativo, retorne listas vazias.

EXEMPLOS (FEW-SHOT):

Texto: "A oposição barrou os avanços da reforma tributária."

Output:

```
{ "schemas": ["FORCE", "PATH"], "details": [
  { "schema_name": "FORCE", "sub_type": "BLOCKAGE",
    "anchor_word_pt": "barrou",
    "target_domain_pt": "Política" },
  { "schema_name": "PATH", "sub_type": "TRAJECTORY",
    "anchor_word_pt": "avanços",
    "target_domain_pt": "Economia" }
]}
```

Texto: "A inflação empurrou as famílias para a crise."

Output:

```
{ "schemas": ["FORCE"], "details": [
```

```

    {"schema_name": "FORCE", "sub_type": "COMPULSION",
     "anchor_word_pt": "empurrou",
     "target_domain_pt": "Economia"}
  ]}

Texto: "Quero saudar a presença do Vereador Júnior."
Output: {"schemas": [], "details": []}

---
Analise o texto a seguir e retorne o JSON estrito.

Texto para análise:
{text}

```

B. Algoritmos IS-RAG

B.1. Pipeline de Indexação

Algorithm 1 Indexação IS-RAG

Entrada: Corpus $\mathcal{D}$, tamanho de trecho $w=150$, encoder $\mathcal{E}$, analisador LLM $\mathcal{P}$

Saída: Repositório vetorial $\mathcal{S}$ populado

```

1: for cada documento  $d \in \mathcal{D}$  do
2:    $C \leftarrow \text{SEMANTICCHUNK}(d, w)$  ▷ divisão em fronteiras de sentença
3:    $\mathbf{E}_t \leftarrow [\mathcal{E}(c) \mid c \in C]$  ▷ embeddings textuais, 768d
4:    $M \leftarrow [\mathcal{P}(c) \mid c \in C]$  ▷ chamadas LLM concorrentes, 5 workers
5:   for  $i \leftarrow 1$  até  $|C|$  do
6:      $\mathbf{e}_c \leftarrow \mathcal{E}(\text{SERIALIZE}(M_i))$  ▷ embedding cognitivo
7:      $\mathcal{S}.\text{INSERT}(C_i, \mathbf{E}_{t,i}, \mathbf{e}_c, M_i)$ 
8:   end for
9: end for

```

B.2. Recuperação em Tempo de Consulta

Algorithm 2 Recuperação IS-RAG

Entrada: Consulta q , modo $m \in \{\text{texto, cognitivo, híbrido}\}$, top- k , repositório $\mathcal{S}$, $\alpha=0,4$, $\beta=0,3$

Saída: Lista ranqueada de k trechos

```

1:  $(\Sigma_q, \Delta_q) \leftarrow \mathcal{P}(q)$  ▷ esquemas e domínios detectados
2:  $\mathbf{e}_{q,t} \leftarrow \mathcal{E}(q)$ ;  $\mathbf{e}_{q,c} \leftarrow \mathcal{E}(\text{SERIALIZE}(\mathcal{P}(q)))$ 
3: for cada trecho  $(C_i, \mathbf{e}_{t,i}, \mathbf{e}_{c,i}, M_i) \in \mathcal{S}$  do
4:    $s_t \leftarrow \cos(\mathbf{e}_{q,t}, \mathbf{e}_{t,i})$ ;  $s_c \leftarrow \cos(\mathbf{e}_{q,c}, \mathbf{e}_{c,i})$ 
5:    $s \leftarrow \begin{cases} s_t & \text{se } m = \text{texto} \\ s_c & \text{se } m = \text{cognitivo} \\ (s_t + s_c)/2 & \text{se } m = \text{híbrido} \end{cases}$ 
6:    $n \leftarrow |M_i.\text{details}|$ 
7:    $\sigma \leftarrow |\{d \in M_i.\text{details} \mid d.\text{schema} \in \Sigma_q\}| / \max(n, 1)$ 
8:    $\delta \leftarrow |\{d \in M_i.\text{details} \mid d.\text{domain} \in \Delta_q\}| / \max(n, 1)$ 
9:    $\hat{s}_i \leftarrow s \cdot (1 + \alpha \sigma + \beta \delta)$  ▷ Eq. 1
10: end for
11: return TOPK( $\{\hat{s}_i\}, k$ )

```
